



UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO
Instituto de Investigaciones en Matemáticas
Aplicadas y en Sistemas
Licenciatura en Ciencia de Datos



CALIDAD Y PREPROCESAMIENTO DE DATOS — PROYECTO FINAL

Calidad e Integración de Fuentes Institucionales

para el Análisis de la Violencia de Género en México

*Perfil estadístico territorial INE-BANAVIM
y registro de pares candidatos de agresores (2020–2022)*

Equipo

Castrillo Cruz Karen Arlet
Pérez Aguiar Oropeza Gabriel Emiliano
Ramos González Nadia
Rueda Reyes Fabián
Torres Pasi6n Angel Isaac

Profesores: MCIC V6ctor Manuel Corza Vargas | MCIC Fernando Avit6a
Varela

Contents

1	Introducción	6
2	Objetivos	7
3	Contexto: Violencia de género en México	8
3.1	Dimensión político-gubernamental	8
3.2	La falla institucional: el BANAVIM que no funciona	8
3.3	El ciclo de impunidad y la necesidad de datos territoriales	9
4	Marco teórico de calidad de datos	9
4.1	Posicionamiento respecto a frameworks establecidos	9
4.1.1	DAMA-DMBOK	9
4.1.2	DQAF — Marco del FMI	9
4.1.3	ISO/IEC 25012	9
4.1.4	TDQM — Total Data Quality Management	10
4.2	Framework propio: IDLA	10
4.3	Pipeline general del proyecto	11
5	Descripción del área de negocio	12
6	Descripción de las fuentes de datos	12
6.1	INE — Registro Nacional de Personas Sancionadas (RNPS)	12
6.2	BANAVIM — Banco Nacional de Datos sobre Violencia contra las Mujeres	14
7	Problemática y entendimiento del negocio	16
8	Propuesta de solución	16
8.1	Herramientas	16
8.2	Preguntas de negocio	17
8.3	Modelo canónico	17
9	Desarrollo de la solución	18
9.1	Fase I — Integrar: ingesta y estandarización	18
9.2	Fase D — Depurar: perfilado y limpieza	18
9.2.1	Perfilado con ydata-profiling	19
9.2.2	Funciones de normalización del INE	19
9.2.3	Reparación de mojibake en BANAVIM	20
9.3	Fase L — Ligar: golden record del INE	21

9.3.1	Por qué el Número de Expediente no puede ser llave	21
9.3.2	Construcción del golden record	21
9.4	Clustering espacial: patrones territoriales (P2)	22
9.4.1	DBSCAN — Density-Based Spatial Clustering	22
9.4.2	K-Means como complemento	23
10	Record linkage individual: registro de pares candidatos	24
10.1	Bases de entrada y su preparación	24
10.2	Homologación semántica con niveles de confianza	25
10.3	Validación geográfica contra catálogo INEGI	25
10.4	Resultado principal: 8 pares de alta confianza	26
10.5	Trazabilidad completa del sistema	26
11	Record linkage territorial: perfil estadístico integrado	27
11.1	Bases de entrada para el SNM	27
11.2	Sorted Neighbourhood Method	27
11.3	Construcción del perfil por estado	28
12	Visualizaciones integradas y hallazgos analíticos	29
12.1	Perfil de personas sancionadas (INE)	30
12.2	Tipos de violencia y relación con las sanciones	30
12.3	Distribución territorial comparada: INE vs BANAVIM	31
12.4	Relaciones víctima-agresor entre fuentes	31
12.5	Perfil sociodemográfico del agresor (BANAVIM)	32
12.6	Índice de riesgo territorial integrado	33
12.7	Consultas analíticas sobre el INE	33
12.8	Consultas analíticas sobre BANAVIM	34
12.9	Consultas multi-fuente (1–5)	35
12.10	Consultas multi-fuente orientadas a política pública (6–10)	36
13	Preguntas de negocio y análisis	37
13.1	P1 — Distribución de violencia y vínculos (INE)	37
13.2	P2 — Patrones territoriales de violencia	38
13.3	P3 — Comparación INE vs BANAVIM: vínculos relacionales	39
13.4	P4 — Perfil del agresor: arma y alcohol (BANAVIM)	40
13.5	P5 — Índice de riesgo territorial	40
14	Conclusiones	42
14.1	En términos del proyecto de calidad de datos	42

14.2 En términos del dominio de negocio	42
---	----

1. Introducción

“Toda información en posesión de cualquier autoridad, entidad, órgano y organismos de los poderes Ejecutivo, Legislativo y Judicial, es pública, pudiendo ser reservada temporalmente por razones de interés público y seguridad nacional, en los términos que fijen las leyes.”

— *Artículo 6°, Constitución Política de los Estados Unidos Mexicanos*

El principio de máxima publicidad consagrado en el artículo 6° constitucional establece que la información en posesión del Estado es, por regla general, pública. Sin embargo, ese derecho no es absoluto: la Segunda Sala de la Suprema Corte de Justicia de la Nación, en la tesis aislada 2a. XXXVI/2019 (10a.), reconoce que cuando el derecho a la información colisiona con el derecho a la privacidad, la autoridad debe ponderar la relevancia pública de la información y las actividades de los sujetos involucrados. Es precisamente en esa tensión donde se sitúa el presente proyecto.

El 2 de diciembre de 2019, la entonces Jefa de Gobierno de la Ciudad de México Claudia Sheinbaum presentó ante el Congreso local la *Iniciativa con Proyecto de Decreto por el que se crea la Ley del Registro Público de Agresores Sexuales de la Ciudad de México*. Dicha iniciativa fijó en su artículo 17 la obligación de que toda autoridad involucrada en el Registro mantenga los datos de los sentenciados “**exactos, completos, correctos y actualizados**”. Entre las fuentes institucionales que deberían nutrir ese registro se encuentra el **Registro Nacional de Personas Sancionadas del Instituto Nacional Electoral (INE)**, que documenta formalmente las sanciones impuestas por violencia política de género.

Así, el proyecto toma dos caminos complementarios: sentar las bases de un **perfil estadístico integrado de la violencia de género** que sirva como insumo para el diseño de políticas públicas territoriales, y documentar el proceso de construcción de un registro de pares candidatos de agresores entre fuentes institucionales —con los obstáculos encontrados.

Para la **primera vía**, el punto de partida es el estado actual del **Banco Nacional de Datos e Información sobre Casos de Violencia contra las Mujeres (BANAVIM)**. Creado en 2007 como el gran repositorio nacional, el BANAVIM no ha cumplido su función original: las fiscalías estatales y dependencias responsables de alimentarlo no lo actualizan de forma periódica, los datos presentan problemas de codificación y nulidad estructural, y la información disponible no permite la integración que el sistema promedia (Soto Espinosa, CIMAC Noticias, 17 de marzo de 2022). En ese marco, el proyecto busca

generar evidencia empírica sobre el comportamiento territorial de la violencia de género a partir de lo que las fuentes disponibles sí permiten analizar, integrando el INE y el BANAVIM a través del municipio como campo homologable. La integración de estas fuentes permite construir un **perfil estadístico territorial** que identifica patrones de concentración de violencia por estado, vínculos relacionales predominantes y zonas de mayor riesgo institucional, produciendo insumos concretos para el diseño de políticas públicas de prevención focalizadas.

Para la **segunda vía**, el proyecto documenta el proceso de construcción de un **registro de pares candidatos de agresores** a partir de la vinculación entre ambas fuentes. Este trabajo parte de la construcción de un *golden record* del INE: mediante la función `consolidar_persona`, las 162 incidencias del periodo 2020–2022 se consolidan en **140 individuos únicos**, identificando 12 reincidentes que no eran visibles en los datos originales. A partir de esa base limpia y trazable, se implementa un proceso de record linkage individual con niveles de confianza diferenciados y validación geográfica contra el catálogo oficial del INEGI. El resultado — **5 pares candidatos de alta confianza** — no es un fracaso metodológico: es la demostración empírica de que los datos existentes no permiten construir el registro que la ley ordena. Esa brecha entre el mandato legal y la infraestructura de datos disponible es, en sí misma, el hallazgo más importante del proyecto.

2. Objetivos

- Diagnosticar y documentar las problemáticas de calidad de datos en el INE y el BANAVIM, evidenciando las limitaciones estructurales para la integración individual.
- Implementar un *pipeline* de perfilado, limpieza y fusión enmarcado en el framework IDLA (Integrar–Depurar–Ligar–Analizar).
- Construir un perfil estadístico integrado de la violencia de género por estado y vínculo relacional, como insumo para políticas públicas de prevención territorial.
- Implementar un proceso de record linkage individual entre INE y BANAVIM con escenarios de confianza diferenciados y trazabilidad completa.
- Responder cinco preguntas de negocio sobre patrones de violencia, vínculos agresor-víctima, perfiles de riesgo y concentración territorial.

3. Contexto: Violencia de género en México

3.1. Dimensión político-gubernamental

La violencia de género representa uno de los desafíos estructurales más persistentes del Estado mexicano. Los datos más recientes confirman que la problemática no solo persiste, sino que se ha agravado en la última década.

Panorama nacional (ENVIPE 2024)

De acuerdo con la ENVIPE 2024, durante 2023 el **27.5%** de los hogares del país tuvo al menos una persona víctima de algún delito, equivalente a **21.9 millones de víctimas**. Las mujeres registraron una tasa de **4,290 delitos sexuales por cada 100,000 habitantes** frente a 465 en hombres —**9 delitos contra mujeres por cada uno contra hombres**. El hallazgo más preocupante: **el 92.9%** de los delitos no se denunció ni originó carpeta de investigación.

Violencia de género estructural (ENDIREH 2021)

- El **70.1%** de las mujeres de 15 años y más ha experimentado al menos una situación de violencia a lo largo de su vida — el dato más alto desde 2006.
- La Ciudad de México ocupa el **segundo lugar nacional** con el **76.2%** de mujeres afectadas.
- La **violencia sexual comunitaria** es la de mayor prevalencia (20%).
- Solo el **13.1%** de las mujeres que sufrieron violencia sexual denunció.

Feminicidios (2024)

Según el SESNSP, en 2024 se registraron **797 víctimas de feminicidio**. Los casos de niñas y adolescentes **aumentaron un 6.7%**. Entre 2014 y 2024, el porcentaje de mujeres que reportó haber sufrido un delito sexual pasó de 0.9% a 2.5% — la incidencia se **casi triplicó** en diez años (Nexos, 2025).

3.2. La falla institucional: el BANAVID que no funciona

El BANAVID fue diseñado en 2007 para ser el gran repositorio nacional. Quince años después, la periodista Angélica Jocelyn Soto Espinosa documentó en CIMAC Noticias (2022) que el sistema no es suministrado periódicamente por las dependencias responsables. Este proyecto demuestra, con análisis de datos, que esa falla no es solo operativa sino estructural: codificación rota, nulidad masiva, ausencia de identificadores de persona y vocabularios incompatibles hacen imposible la integración que el sistema promedía.

3.3. El ciclo de impunidad y la necesidad de datos territoriales

Sin información integrada y confiable por territorio, es imposible:

1. Identificar municipios con mayor concentración de casos.
2. Evaluar la efectividad territorial de las sanciones impuestas.
3. Diseñar intervenciones preventivas focalizadas.
4. Hacer seguimiento de reincidentes por entidad federativa.

4. Marco teórico de calidad de datos

4.1. Posicionamiento respecto a frameworks establecidos

4.1.1. DAMA-DMBOK

El *Data Management Body of Knowledge* (DAMA International, 2017) define la gestión de calidad como una función continua con dimensiones medibles y un ciclo de mejora. Las dimensiones adoptadas —completitud, exactitud, consistencia, unicidad y actualidad— son directamente compatibles con las del DMBOK. El concepto de *Data Lineage* es la base de la trazabilidad del proyecto, operacionalizado mediante el campo **fuelle** presente en todo registro del pipeline.

4.1.2. DQAF — Marco del FMI

El *Data Quality Assessment Framework* (FMI, 2012) fue diseñado para evaluar estadísticas oficiales de instituciones gubernamentales —exactamente el tipo de fuentes de este proyecto. Sus *prerrequisitos de calidad* justifican asignar distinto peso al INE (resolución formal con expediente) frente al BANAVIM (caso atendido, no necesariamente sancionado). Su *garantía de integridad* sustenta el requisito de trazabilidad del perfil municipal generado.

4.1.3. ISO/IEC 25012

La norma ISO/IEC 25012 (*Data Quality Model*, 2008) es el referente técnico más directo para la selección de dimensiones:

Dimensión del proyecto	Característica ISO/IEC 25012
Compleitud	Completeness
Exactitud / Validez	Accuracy
Consistencia	Consistency
Credibilidad	Credibility
Actualidad	Currentness
Trazabilidad	Traceability
Conformidad	Compliance

Table 1: Correspondencia entre dimensiones del proyecto y la norma ISO/IEC 25012.

La *aptitud para vinculación* no aparece explícitamente en la norma. Es una dimensión operacional derivada de completitud, exactitud y consistencia, construida para evaluar si un registro puede participar en el proceso de record linkage. Resultó ser la métrica más determinante del pipeline.

4.1.4. TDQM — Total Data Quality Management

El modelo TDQM (Wang & Strong, 1996) introduce el concepto de *fitness for use*: la calidad solo tiene sentido en relación con el uso que se hará de los datos. Establece además que distintas fases del pipeline requieren distintas dimensiones —completitud y validez se evalúan antes de limpiar; trazabilidad y unicidad del registro maestro solo pueden evaluarse después de la fusión.

4.2. Framework propio: IDLA

A partir de los cuatro referentes anteriores, el equipo diseñó el framework **IDLA** (Integrar–Depurar–Ligar–Analizar), que operacionaliza sus principios en el contexto específico de integración de fuentes institucionales heterogéneas sin identificador común:

Fase	Dimensiones activas	Decisión que habilita	Referente
Integrar	Conformidad, trazabilidad, credibilidad	Qué fuentes entran y con qué peso institucional	DQAF
Depurar	Compleitud, exactitud, consistencia	Qué campos se limpian, imputan o descartan	DAMA, ISO/IEC 25012
Ligar	Aptitud para vinculación, unicidad	Qué tipo de fusión es posible con los datos disponibles	TDQM, ISO/IEC 25012
Analizar	Compleitud analítica, validez	Qué consultas y gráficas son válidas sobre el perfil municipal	DAMA, TDQM

Table 2: Fases del framework IDLA y su anclaje teórico.

4.3. Pipeline general del proyecto

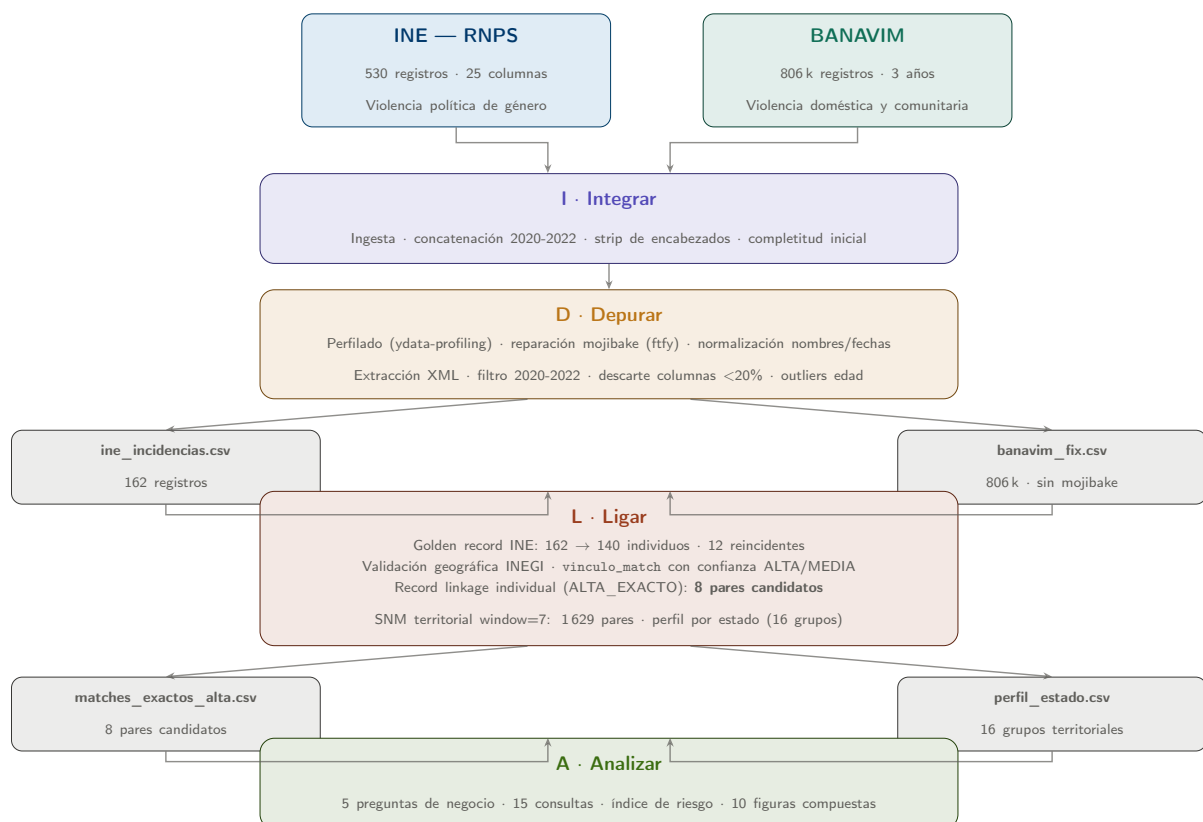


Figure 1: Pipeline del proyecto bajo el framework IDLA con datos reales.

5. Descripción del área de negocio

El sector de trabajo es **Seguridad Pública y Política de Género**. El usuario potencial son las dependencias responsables del diseño de políticas públicas: CONAVIM, INMUJERES y las secretarías de las mujeres de los gobiernos estatales. El producto del proyecto —perfil territorial de riesgo y registro de candidatos— es exactamente el tipo de insumo que estas instituciones necesitan para priorizar intervenciones y diseñar programas de prevención focalizados.

Las necesidades de negocio que este proyecto aborda son:

- Contar con un diagnóstico documentado de por qué el BANAVIM no puede utilizarse como registro maestro en su estado actual.
- Disponer de un perfil estadístico que integre la dimensión de sanción política (INE) con la dimensión de violencia doméstica y comunitaria (BANAVIM).
- Identificar estados con mayor concentración de casos y perfiles de riesgo diferenciados como insumo para intervenciones territoriales.
- Documentar el proceso y los obstáculos de intentar construir un registro de agresores vinculando fuentes institucionales heterogéneas, dejando las bases metodológicas para cuando los datos mejoren.

6. Descripción de las fuentes de datos

6.1. INE — Registro Nacional de Personas Sancionadas (RNPS)

Característica	Valor
Tipo de archivo	.xlsx (estructurado)
Registros totales	530
Registros 2020–2022	162 (tras filtro temporal)
Columnas	25 (9 tras descarte por baja completitud)
Institución	Instituto Nacional Electoral
Ámbito	Nacional · Cobertura 2014–2025
Marco legal	LGAMVLV Art. 20 Bis; Protocolo TEPJF-INE (2017/2020)

Table 3: Ficha técnica de la fuente INE.

El INE registra personas **sancionadas formalmente** por violencia política de género en el ámbito electoral e institucional. Sus categorías de relación agresor-víctima reflejan estructuras de poder político: PARES, JERARQUICA, SUBORDINACION, definidas por el Protocolo

TEPJF-INE y el Art. 20 Bis de la LGAMVLV (2020).

Problemas de calidad identificados:

- Cuatro columnas con nulidad del 100%: Calidad/Cargo, Modalidad de violencia, Intersección de la víctima y Perteneciente a. Descartadas del análisis.
- Tipo de violencia almacena XML crudo (e.g. <element>Simbólica</element>), inutilizable sin preprocesamiento.
- Permanencia mezcla dos formatos de fecha (DD/MM/YYYY y YYYY-MM-DDTHH:MM:SS) e incluye el valor literal “Indeterminada”.
- Nombre incluye alias y apodos en lugar de nombres reales.
- 29.8% de nulidad en Municipio; 13% en Entidad Federativa.
- Una misma persona aparece en múltiples filas (una por incidencia), sin consolidación de identidad entre registros.




Figure 2: Completitud por campo en la fuente INE (antes de limpieza).

6.2. BANAVIM — Banco Nacional de Datos sobre Violencia contra las Mujeres

Característica	Valor
Tipo de archivo	.xlsx (hoja Agresores)
Registros	265,760 (2020) + 285,984 (2021) + 254,348 (2022) = 806,092
Columnas	28 por año
Institución	CONAVIM / SEGOB
Fuente de acceso	Plataforma Nacional de Transparencia (solicitud de acceso)
Marco legal	LGAMVLV (todos los ámbitos); NOM-046-SSA2-2005

Table 4: Ficha técnica de la fuente BANAVIM.

Los campos disponibles incluyen: Identificador Único, Edad del Agresor, Sexo, Escolaridad, Estado Civil, Fecha de registro, Estado donde reside, Municipio donde reside, Relación o vínculo con la víctima, indicadores de consumo de sustancias (Droga_Alcohol, Droga_Drogas Ilegales) y posesión de armas (Portaba Dicha Arma, ArmaFuegoCorta, Machete, entre otros).

Problemas de calidad identificados:

- **Ausencia de nombre del agresor:** impide cualquier vinculación individual directa con el INE.
- **Identificador Único** es un ID de sistema (no de persona): no permite rastrear al mismo individuo entre años ni entre fuentes.
- **Mojibake sistémico:** AcapulcodeJuarez en lugar de Acapulco de Juárez. El mismo municipio aparece correctamente en el INE y corrompido en el BANAVIM, constituyendo un caso real y documentado de entidades geográficas nombradas de forma incompatible entre fuentes institucionales.
- Nulidad variable por campo, año y entidad reportante.
- Valores atípicos en **Edad del Agresor** (edades menores a 14 o mayores a 85 años).

Ejemplos de reparación de mojibake en BANAVIM

Campo	Antes (corrupto)	Después (normalizado)
Escolaridad	Carrera tÃ©cnica comercial	Carrera tÃ©cnica comercial
Estado	Ciudad de MÃ©xico	Ciudad de MÃ©xico
Estado	Nuevo LeÃ³n	Nuevo LeÃ³n
Municipio	JesÃºs MarÃ­a	JesÃºs MarÃ­a
Municipio	PabellÃ³n de Arteaga	PabellÃ³n de Arteaga
VÃ­nculo	CÃ³nyuge o pareja	CÃ³nyuge o pareja
VÃ­nculo	CompaÃ±ero(a)	CompaÃ±ero(a)
VÃ­nculo	Servidor pÃºblico	Servidor pÃºblico

Figure 3: Ejemplos representativos de reparaci3n de mojibake y normalizaci3n textual en variables categoricas del BANAVIM.

Heterogeneidad de fen3menos: El INE registra violencia en el 3mbito polÃ­tico-electoral (agresores que son funcionarios, candidatos o militantes); el BANAVIM registra violencia dom3stica, comunitaria, laboral e institucional. La fusi3n no pretende identificar a las mismas personas, sino construir un perfil territorial que integre ambas dimensiones de un mismo fen3meno estructural.

7. Problemática y entendimiento del negocio

#	Problemática	Dimensión afectada
P1	Imposibilidad de construir perfiles sociodemográficos confiables del agresor por alta tasa de nulidad en campos clave del BANAVID (Estado Civil: 50.1%, Edad: 17.9%).	Complejidad
P2	Análisis territorial sesgado: 29.8% de nulidad en Municipio del INE y registro no uniforme entre entidades reportantes en el BANAVID.	Complejidad / Actualidad
P3	Imposibilidad de fusión individual directa: el BANAVID omite el nombre del agresor y usa vocabularios y codificaciones incompatibles con el INE.	Aptitud para vinculación / Consistencia
P4	El campo Tipo de violencia del INE es inutilizable en estado crudo (XML embebido), impidiendo clasificar conductas para análisis.	Exactitud / Conformidad
P5	Pérdida de trazabilidad por reincidentes: la misma persona aparece en múltiples registros sin consolidación, distorsionando el conteo real de agresores.	Unicidad / Integridad

Table 5: Problemáticas de negocio y dimensiones de calidad afectadas.

8. Propuesta de solución

8.1. Herramientas

- **Python 3.12**: lenguaje principal para todo el pipeline.
- **pandas / numpy**: manipulación y transformación de datos tabulares.
- **ftfy** (*fixes text for you*): reparación automática de mojibake.
- **unidecode / jellyfish**: transliteración Unicode y similitud de cadenas.
- **recordlinkage**: indexación (SNM), comparación y evaluación de pares.
- **networkx**: componentes conexos en clusters de registros.

- **ydata-profiling**: reportes interactivos de perfilado en formato HTML.
- **geopy**: geocodificación de municipios para clustering espacial.
- **scikit-learn**: clustering (DBSCAN, K-Means) y normalización (MinMaxScaler).
- **matplotlib** / **seaborn**: visualización de datos.

8.2. Preguntas de negocio

1. **¿Cómo se distribuyen los tipos de violencia y sanciones en el INE?**
Análisis descriptivo: frecuencias, tablas de contingencia y gráficas.
2. **¿Qué patrones territoriales existen en las denuncias y sanciones?**
Clustering espacial (DBSCAN y K-Means) sobre coordenadas geocodificadas.
3. **¿Qué relaciones víctima-agresor y tipos de violencia aparecen con mayor frecuencia?**
Análisis comparativo de frecuencias entre INE y BANAVIM.
4. **¿Qué características del agresor se asocian con portar arma o consumir alcohol?**
Análisis descriptivo comparativo sobre BANAVIM (806 k registros).
5. **¿Qué estados presentan mayor índice de riesgo territorial?**
Índice compuesto ponderado sobre el perfil integrado INE–BANAVIM.

8.3. Modelo canónico

La entidad maestra del proyecto es el **municipio** / **estado**. Dos versiones del campo de vínculo coexisten en el pipeline: `vinculo_grupo` (para el análisis territorial y el SNM) y `vinculo_match` (para el record linkage individual, más estricto):

Campo canónico	Fuente INE	Fuente BANAVIM
municipio	Municipio (normalizado)	Municipio donde reside (ftfy)
estado	Entidad Federativa	Estado donde reside
sexo	Sexo (H/M)	Sexo (H/M)
vinculo_match	Relación (ALTA/MEDIA)	Vínculo (ALTA/MEDIA)
tipo_violencia	XML → texto	—
sancion	Sanción	—
fecha	Fecha De La Resolución	Fecha de registro
edad_agresor	—	Edad del Agresor
portaba_arma	—	Portaba Dicha Arma
alcohol	—	Droga_Alcohol
es_reincidente	Derivado (golden record)	—
fuelle	“INE”	“BANAVIM”

Table 6: Modelo canónico integrado INE–BANAVIM.

9. Desarrollo de la solución

9.1. Fase I — Integrar: ingesta y estandarización

El INE se carga directamente desde `.xlsx`. El BANAVIM se precargó en archivos `.pkl` por eficiencia —los archivos originales superan los 35 MB cada uno— y se concatena antes de cualquier transformación. Un paso crítico inmediato es eliminar espacios residuales en los nombres de columna, que de otro modo generan errores silenciosos al acceder a campos por nombre exacto.

```

1 df_ine_raw = pd.read_excel('../Data/Registro-nacional-de-personas-
    sancionadas (INE).xlsx')
2 df_ine_raw.columns = df_ine_raw.columns.str.strip()
3
4 # BANAVIM precargado en pkl para evitar parsear ~35MB por a o
5 with open('bv_2020.pkl', 'rb') as f: bv_2020 = pickle.load(f)
6 with open('bv_2021.pkl', 'rb') as f: bv_2021 = pickle.load(f)
7 with open('bv_2022.pkl', 'rb') as f: bv_2022 = pickle.load(f)
8 bv = pd.concat([bv_2020, bv_2021, bv_2022], ignore_index=True)
9 print(f'INE: {df_ine_raw.shape} | BANAVIM: {bv.shape}')
10 # INE: (530, 25) | BANAVIM: (806092, 28)

```

Listing 1: Ingesta y normalización de encabezados.

9.2. Fase D — Depurar: perfilado y limpieza

9.2.1. Perfilado con ydata-profiling

Biblioteca ydata-profiling: genera un reporte HTML interactivo y completo de un DataFrame. Analiza automáticamente tipos de variables, distribuciones, correlaciones, valores faltantes y alertas de calidad. El parámetro `explorative=True` activa análisis más profundos de correlaciones e interacciones. Se generaron reportes antes y después de la limpieza para documentar las transformaciones.

Fuente	Columna	% Nulos	Severidad
INE	Calidad/Cargo / Modalidad / Intersección	100.0%	Crítica
INE	Cumple modo honesto	90.6%	Alta
INE	Municipio / Entidad Federativa	29.8% / 13.0%	Media
BANAVIM	Estado Civil	50.1%	Alta
BANAVIM	Edad / Sexo / Vínculo	17.9% / 17.6% / 16.2%	Media

Table 7: Resumen de nulidad en fuentes brutas.

9.2.2. Funciones de normalización del INE

Función `normalizar_nombre(texto)`: convierte el nombre del sujeto a minúsculas, elimina acentos mediante `unidecode` (que transliteran caracteres Unicode a su equivalente ASCII más cercano), quita caracteres no alfabéticos y colapsa espacios múltiples. Devuelve `None` si el valor original era nulo, preservando correctamente los valores faltantes de pandas. Esta función es fundamental para detectar reincidentes: sin ella, “JUAN GARCÍA” y “juan garcia” se tratarían como personas distintas.

Función `parsear_fecha(valor)`: maneja la heterogeneidad de formatos en el campo `Permanencia`. Itera sobre los formatos `DD/MM/YYYY` y `YYYY-MM-DDTHH:MM:SS`, y convierte el valor literal “Indeterminada” a `pd.NaT` (valor nulo de tiempo en pandas). Usa `errors='coerce'` como fallback para valores no parseables, garantizando que ningún error detenga el pipeline.

Función `extraer_xml_lista(texto)`: extrae los valores encerrados en etiquetas `<element>` del campo `Tipo de violencia`, que el INE almacena como XML crudo en texto plano. Usa expresiones regulares (`re.findall`) y concatena los elementos extraídos con separador `|` para preservar múltiples tipos en un solo campo legible.

```

1 def normalizar_nombre(texto):
2     """Minusculas, sin acentos, sin puntuacion, espacios colapsados.
3     Devuelve None para nulos, preservando NaN de pandas."""
4     if pd.isna(texto) or not str(texto).strip(): return None
5     t = unidecode(str(texto)).lower()

```

```

6     t = re.sub(r'[^a-z\s]', ' ', t)
7     return re.sub(r'\s+', ' ', t).strip() or None
8
9 def extraer_xml_lista(texto):
10     """Extrae valores de <element> en campos XML crudos del INE."""
11     if pd.isna(texto) or not str(texto).strip(): return None
12     elementos = re.findall(r'<element>([^\>]+)</element>', str(texto))
13     return ' | '.join(e.strip() for e in elementos) if elementos else
        None
14
15 ine = ine[ine['fecha_resolucion'].dt.year.between(2020, 2022)]
16 # 530 -> 162 registros tras el filtro temporal
17 completitud_ine = (1 - df_ine_raw.isnull().mean()) * 100
18 ine = ine.drop(columns=completitud_ine[completitud_ine < 20].index)
19 # Se descartan 4 columnas criticas y otras con <20% completitud
20 # Quedan 9 columnas utiles de las 25 originales

```

Listing 2: Funciones de normalizacion y su aplicacion al INE.

9.2.3. Reparación de mojibake en BANAVIM

El BANAVIM presenta un problema de codificación sistémico: los caracteres acentuados aparecen corrompidos en todos sus campos de texto. Este fenómeno —conocido como *mojibake*— ocurre cuando un texto codificado en UTF-8 es leído como si fuera Latin-1 u otro esquema distinto. El caso documentado más claro es el municipio Acapulco de Juárez, que aparece como AcapulcodeJuarez en el BANAVIM pero correctamente escrito en el INE. Este ejemplo demuestra empíricamente por qué ambas fuentes no pueden unirse directamente sin limpieza previa.

Biblioteca `ftfy` (*fixes text for you*): analiza cadenas de texto y detecta y corrige automáticamente problemas comunes de codificación. Usa heurísticas basadas en la frecuencia de caracteres en diferentes esquemas para inferir y revertir las conversiones erróneas.

```

1 from ftfy import fix_text
2
3 def reparar_codificacion(x):
4     """Aplica fix_text a strings; preserva NaN."""
5     if pd.isna(x): return np.nan
6     s = str(x).strip()
7     return fix_text(s) if s else np.nan
8
9 bv_fix = bv.copy()
10 for col in bv.select_dtypes(include="object").columns:

```

```

11     bv_fix[col] = bv_fix[col].apply(reparar_codificacion)
12 # 806,092 registros procesados en todos los campos de texto
13 # Ejemplo: 'AcapulcodeJuarez' -> 'Acapulco de Juarez'

```

Listing 3: Deteccion y reparacion de mojibake con ftfy.

9.3. Fase L — Ligar: golden record del INE

9.3.1. Por qué el Número de Expediente no puede ser llave

El campo Número De Expediente identifica un *proceso legal*, no a un individuo. Produce error en ambas direcciones: un mismo expediente puede involucrar a múltiples personas (falsos positivos), mientras que una persona reincidente genera expedientes nuevos por cada falta (falsos negativos). Por esta razón se descartó como criterio de emparejamiento.

9.3.2. Construcción del golden record

Función `consolidar_persona(df_grupo)`: recibe todas las filas del mismo nombre normalizado y produce un único diccionario-registro maestro. Los campos **invariantes** (sexo, entidad, municipio) se resuelven por moda —el valor más frecuente entre las incidencias, eligiendo el de mayor longitud en caso de empate para preservar información. Los campos **por incidencia** (conducta, sanción, expediente, fecha) se conservan como listas ordenadas cronológicamente. Se derivan los campos `n_incidencias` (número total de filas del grupo) y `es_reincidente` (booleano: True si `n_incidencias > 1`).

```

1 def consolidar_persona(df_grupo: pd.DataFrame) -> dict:
2     """Agrupa todas las filas del mismo nombre en un registro maestro
3     .
4     - Campos invariantes: resueltos por moda (mayor longitud en
5     empate)
6     - Campos por incidencia: listas ordenadas cronologicamente
7     - Derivados: n_incidencias, es_reincidente"""
8     df_grupo = df_grupo.sort_values('fecha_resolucion', na_position='
9     last')
10    gr = {}
11    gr['Nombre'] = max(df_grupo['Nombre'].dropna().tolist(),
12                      key=lambda x: len(str(x)), default=None)
13    for col in CAMPOS_INVARIANTES:
14        vals = df_grupo[col].dropna()
15        gr[col] = max(vals.mode().tolist(),
16                      key=lambda x: len(str(x))) if len(vals) > 0
17    else None
18    for col in CAMPOS_POR_INCIDENCIA:

```

```

15     gr[col] = [None if pd.isna(v) else v for v in df_grupo[col].
    tolist()]
16     gr['n_incidentes'] = len(df_grupo)
17     gr['es_reincidente'] = len(df_grupo) > 1
18     return gr
19
20 registros_golden = []
21 for nombre, df_grupo in ine_con_nombre.groupby('Nombre', sort=False):
22     registros_golden.append(consolidar_persona(df_grupo))
23 df_golden = pd.DataFrame(registros_golden)
24 # 162 registros -> 140 individuos unicos | 12 reincidentes
    identificados

```

Listing 4: Consolidación de registros por persona (golden record).

Hallazgo P5: *Ernesto Ruiz Flandes* (Veracruz) acumula **10 incidentes** entre 2020 y 2022, todas con sanción “Ninguna”, relacionadas con la vulneración sistemática del ejercicio del cargo de una regidora municipal. Este perfil no era visible en los datos originales por la fragmentación en filas separadas. El golden record lo hace visible como el agresor más reincidente del registro en el periodo analizado.

9.4. Clustering espacial: patrones territoriales (P2)

Para identificar patrones geográficos de concentración de violencia, se geocodificaron los registros del INE mediante **geopy** (que convierte nombres de lugar a coordenadas lat/lon usando la API de Nominatim) y se aplicaron dos algoritmos de clustering sobre las coordenadas normalizadas.

9.4.1. DBSCAN — Density-Based Spatial Clustering

Algoritmo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*): identifica clusters de forma arbitraria basados en densidad local. No requiere especificar el número de clusters de antemano. Clasifica cada punto como: **core point** (tiene al menos **min_samples** vecinos dentro de radio **eps**), **border point** (alcanzable desde un core point) o **noise** (etiquetado como -1 , no pertenece a ningún cluster). Es especialmente útil para datos geográficos porque detecta concentraciones reales sin asumir forma circular.

El parámetro **eps** define la distancia máxima entre dos puntos para considerarlos vecinos; **min_samples** define cuántos vecinos necesita un punto para ser core. Ambos se ajustaron empíricamente dado el pequeño tamaño del INE (162 registros).

9.4.2. K-Means como complemento

Algoritmo K-Means: divide los datos en k grupos minimizando la suma de distancias cuadradas al centroide de cada grupo. A diferencia de DBSCAN, requiere especificar k de antemano. Se utilizó con $k = 5$ (correspondiente a las cinco regiones geográficas convencionales de México) para comparar con los clusters naturales de DBSCAN.

```

1 from sklearn.cluster import DBSCAN, KMeans
2 from sklearn.preprocessing import StandardScaler
3 from geopy.geocoders import Nominatim
4
5 # Geocodificacion: nombre de municipio/estado -> lat/lon
6 geolocator = Nominatim(user_agent="calidad_datos_unam")
7 ine_geo = ine_fusion.copy()
8 ine_geo[['latitud', 'longitud']] = ine_geo['estado_municipio'].apply(
9     lambda x: pd.Series(geocodificar(x, geolocator))
10 )
11 # Resultado guardado en ine_fusion_geo.csv y golden_g_geo.csv
12
13 # Normalizacion de coordenadas (media=0, std=1)
14 X_geo = StandardScaler().fit_transform(
15     coords_ine[['latitud', 'longitud']].dropna()
16 )
17
18 # DBSCAN: detecta clusters de densidad sin definir k
19 db = DBSCAN(eps=0.4, min_samples=2).fit(X_geo)
20 coords_ine['cluster_dbSCAN'] = db.labels_
21 n_clusters = len(set(db.labels_)) - (1 if -1 in db.labels_ else 0)
22 print(f'Clusters DBSCAN: {n_clusters} | Ruido: {(db.labels_ == -1).sum()} puntos')
23
24 # K-Means: segmentacion en k=5 regiones
25 km = KMeans(n_clusters=5, random_state=42, n_init=10)
26 coords_ine['cluster_kmeans'] = km.fit_predict(X_geo)

```

Listing 5: Geocodificacion y clustering espacial de registros INE.

Hallazgo P2: El clustering DBSCAN identifica una concentración principal en el sur-sureste del país (Oaxaca, Chiapas, Tabasco) y puntos atípicos dispersos en el norte y occidente. Los patrones son consistentes entre DBSCAN y K-Means para el centro-sur, confirmando que la violencia política de género no es un fenómeno uniformemente distribuido: hay estados donde la densidad de casos es estructuralmente mayor, coincidiendo con entidades donde los contextos políticos locales presentan mayor

conflictividad de género documentada.




Figure 4: Incidencias codificadas geográficamente según la latitud y longitud de donde ocurrieron, dataset INE. Clustering con HDBSCAN.

10. Record linkage individual: registro de pares candidatos

Esta sección documenta la segunda vía del proyecto: el intento de identificar pares candidatos entre registros individuales del INE y del BANAVIM. El resultado es la aportación metodológica más importante del equipo y constituye en sí mismo un hallazgo de calidad de datos. Todo el proceso se implementó en `fusion_individuos.ipynb`.

10.1. Bases de entrada y su preparación

Las bases de entrada al linkage individual son versiones **reducidas y normalizadas** de las fuentes principales:

`ine_fusion_2020_2022.csv`: versión canónica del INE con los campos necesarios para la vinculación: `id_ine_caso` (identificador técnico INE_XXXXX), `sexo`, `estado`, `municipio`, `estado_municipio` (concatenado para bloqueo exacto), `vinculo_victima`, `vinculo_match` y `confianza_vinculo_match`. Contiene 162 registros.

`banavim_fusion_2020_2022.csv.gz`: versión canónica del BANAVIM con los mismos campos homologados, más `id_bv_caso` (identificador técnico BV_XXXXXXX). Contiene 806,092 registros. Se comprime en `.gz` por su tamaño. El `id_bv_caso` es el único mecanismo de trazabilidad de vuelta al archivo original, ya que el Identificador Único del BANAVIM no es un identificador de persona.

Por qué no se usa directamente bv o bv_fix: Las bases `bv_fusion` son versiones reducidas y normalizadas diseñadas específicamente para la fusión. Usar la base completa (806k registros con 28 columnas) en el linkage aumentaría el costo computacional innecesariamente y podría introducir inconsistencias si los campos no están normalizados al mismo vocabulario que el INE.

10.2. Homologación semántica con niveles de confianza

El campo de vínculo con la víctima usa vocabularios radicalmente distintos en cada fuente. Para el record linkage individual se construyó la variable `vinculo_match`, más estricta que `vinculo_grupo`, con nivel de confianza explícito:

Fuente	Valor original	vinculo_match	Confianza
INE	PARES	PARES	ALTA
BANAVIM	COMPANERO A	PARES	ALTA
INE	JERARQUICA	JERARQUICA_SUBORDINACION	ALTA
BANAVIM	JEFE A O PATRON A	JERARQUICA_SUBORDINACION	ALTA
INE/BV	OTRO, OTRA	OTRO_RESIDUAL	MEDIA
INE/BV	DESCONOCIDO	SIN_RELACION_IDENTIFICABLE	MEDIA
Ambas	Categorías no comparables	NO_APTO_MATCH	NO_APTO

Table 8: Clasificación de confianza semántica del vínculo para record linkage.

Los registros marcados como `NO_APTO` se excluyen del linkage. Los de confianza `MEDIA` se conservan como análisis de sensibilidad pero no como resultado principal.

10.3. Validación geográfica contra catálogo INEGI

Antes del linkage se validó el campo geográfico comparando los pares `estado + municipio` contra el catálogo oficial de municipios del INEGI. Se aplicaron correcciones solo donde existía justificación clara (localidad o cabecera municipal usada en lugar del municipio oficial):

Estado	Valor original	Valor corregido
CAMPECHE	CIUDAD DEL CARMEN	CARMEN
CAMPECHE	SAN FRANCISCO DE CAMPECHE	CAMPECHE
CAMPECHE	XPUJIL	CALAKMUL
COLIMA	CIUDAD DE ARMERIA	ARMERIA
COLIMA	CIUDAD DE VILLA DE ALVAREZ	VILLA DE ALVAREZ
NAYARIT	EL NAYAR	DEL NAYAR

Table 9: Correcciones geográficas aplicadas contra catálogo INEGI.

Base	Escenario	Registros	Validados	No valid.	% valid.
INE	ALTA	98	95	3	96.94%
BANAVIM	ALTA	3,824	3,757	67	98.25%
INE	ALTA_MEDIA	128	125	3	97.66%
BANAVIM	ALTA_MEDIA	34,782	34,157	625	98.20%

Table 10: Resultados de validación geográfica por escenario.

10.4. Resultado principal: 8 pares de alta confianza

El bloqueo exacto en `estado_municipio + sexo + vinculo_match` con solo categorías de confianza ALTA produjo **8 pares candidatos**:

id_ine	id_bv	estado_municipio	sexo	vinculo_match
INE_00042	BV_0051663	HIDALGO – ZIMAPAN	H	JERARQUICA_SUBORDI
INE_00055	BV_0790702	VERACRUZ – PEROTE	H	PARES
INE_00074	BV_0571922	COAHUILA – FRANCISCO I MADERO	H	PARES
INE_00075	BV_0154241	MORELOS – TETELA DEL VOLCAN	H	JERARQUICA_SUBORDI
INE_00075	BV_0156652	MORELOS – TETELA DEL VOLCAN	H	JERARQUICA_SUBORDI
INE_00075	BV_0689665	MORELOS – TETELA DEL VOLCAN	H	JERARQUICA_SUBORDI
INE_00075	BV_0690933	MORELOS – TETELA DEL VOLCAN	H	JERARQUICA_SUBORDI
INE_00136	BV_0193398	PUEBLA – FRANCISCO Z MENA	H	JERARQUICA_SUBORDI

Table 11: 8 pares candidatos de alta confianza (escenario ALTA_EXACTO).

10.5. Trazabilidad completa del sistema

Una característica central del sistema implementado es que, dado un caso del INE, es posible recuperar: (1) la fila completa limpia del INE; (2) la fila normalizada usada para fusión; (3) los pares candidatos generados; (4) las filas originales del BANAVIM en Excel; y (5) las filas limpias y normalizadas del BANAVIM correspondientes. Esto permite auditar cómo un registro llegó a ser candidato y revisar si la coincidencia es plausible.

Interpretación: Los 8 pares son *candidatos compatibles para revisión*, no matches definitivos. La coincidencia exacta indica compatibilidad observada, no identidad probada. Cualquier uso requiere revisión manual. El escenario ampliado (ALTA_MEDIA) genera ~1,551 pares, pero la mayoría proviene de OTRO_RESIDUAL: solo en Quintana Roo se generan 1,255 candidatos para un único registro INE, lo que evidencia la baja especificidad

de las categorías residuales. Por ello se conserva como análisis de sensibilidad únicamente.

11. Record linkage territorial: perfil estadístico integrado

Dado que el linkage individual produce solo 8 pares de alta confianza, se implementó paralelamente una fusión estadística-territorial que no afirma identidad individual.

11.1. Bases de entrada para el SNM

Las bases de entrada son **diferentes** a las del linkage individual:

`ine_fusion` contiene los 162 registros del INE 2020–2022, con campos canónicos normalizados: `municipio` (sin acentos, sin espacios extra), `estado`, `sexo` (H/M), y `vinculo_grupo` (versión más amplia que `vinculo_match`, que agrupa categorías bajo criterios conceptuales en lugar de semánticos estrictos). Incluye además `id_ine_caso` para trazabilidad.

`bv_fusion` contiene los 806,092 registros del BANAVID con los mismos campos canónicos normalizados, más los campos contextuales del perfil del agresor (`edad`, `escolaridad`, `estado_civil`, `Portaba Dicha Arma`, `Droga_Alcohol`) que enriquecerán el registro maestro resultante.

Los registros dorados resultantes se generan automáticamente con los nombres: `perfil_estado_integrado.csv`, `matches_snm.csv`, `perfil_municipio_integrado.csv`

Por qué `vinculo_grupo` y no `vinculo_match` en el SNM: El SNM no busca identificar a la misma persona, sino encontrar contextos geográficos y relacionales comparables. Por ello se usa la versión menos estricta del vínculo, que produce más candidatos territoriales útiles para el perfil estadístico.

11.2. Sorted Neighbourhood Method

Por qué SNM y no producto cartesiano: comparar 162 registros INE contra 806 k BANAVID produciría 130 millones de comparaciones. El SNM (*Sorted Neighbourhood Method*) ordena ambas bases por la llave de emparejamiento (`municipio` normalizado) y compara solo los registros que quedan vecinos en ese orden, reduciendo a 344,202 pares candidatos. El parámetro `window=7` significa que cada registro se compara con sus 7 vecinos más cercanos en el ordenamiento alfabético.

```
1 import recordlinkage
2
3 # SNM: ordena por municipio y compara solo vecinos (window=7)
4 indexer = recordlinkage.Index()
```

```

5 indexer.sortedneighbourhood(
6     left_on='municipio', right_on='municipio', window=7
7 )
8 candidatos = indexer.index(ine_fusion, bv_fusion)
9 # Resultado: 344,202 pares candidatos (vs 130M del producto
   cartesiano)
10
11 # Comparacion de tres campos con metricas distintas
12 comparador = recordlinkage.Compare()
13 # Jaro-Winkler: similitud de strings que pondera mas los primeros
   caracteres
14 comparador.string('municipio','municipio',
15                   method='jarowinkler', threshold=0.85, label='
   sim_municipio')
16 # Exact: coincidencia exacta (0 o 1)
17 comparador.exact('vinculo_grupo','vinculo_grupo', label='sim_vinculo'
   )
18 comparador.exact('sexo','sexo', label='sim_sexo')
19
20 features = comparador.compute(candidatos, ine_fusion, bv_fusion)
21 # Score total: suma de las tres similitudes (max = 3.0)
22 features['score'] = features[['sim_municipio','sim_vinculo','sim_sexo
   ']].sum(axis=1)
23 features['idx_ine'] = features.index.get_level_values(0)
24 features['idx_bv'] = features.index.get_level_values(1)
25
26 # Umbral >= 2.5: requiere municipio muy similar + al menos un campo
   exacto
27 matches = features[features['score'] >= 2.5]
28 # 1,629 pares vinculados | 24 registros INE | 1,581 del BANAIVIM

```

Listing 6: Sorted Neighbourhood Method para vinculacion territorial.

11.3. Construcción del perfil por estado

Los pares vinculados se enriquecen con los datos contextuales del BANAIVIM y se agrupan al nivel de **estado** para mayor robustez estadística (agregar al nivel de municipio con solo 162 registros del INE produciría grupos demasiado pequeños para ser informativos):

```

1 def pct_si(series):
2     """Calcula el porcentaje de valores 'SI' manejando nulos."""
3     return (series.fillna('').astype(str).str.upper() == 'SI').mean()
4
5 # Agregacion por estado y tipo de vinculo
6 perfil_estado = (

```

```

7 matches_full
8 .groupby(['estado_ine', 'vinculo_grupo_ine'])
9 .agg(
10     n_sanciones_ine = ('idx_ine', 'nunique'), # sanciones
    formales unicas
11     n_casos_banavim = ('idx_bv', 'nunique'), # casos BANAVIM
    unicos
12     edad_media_bv = ('edad_bv', 'mean'), # edad media
    del agresor
13     municipios_unicos = ('municipio_ine', 'nunique'),
14 ).reset_index()
15 .merge(perfil_arma, on=['estado_ine', 'vinculo_grupo_ine'])
16 .merge(perfil_alcohol, on=['estado_ine', 'vinculo_grupo_ine'])
17 .sort_values('n_sanciones_ine', ascending=False)
18 )
19 # 16 grupos estado-vinculo generados

```

Listing 7: Perfil estadístico por estado a partir de los matches.

Perfil por estado (16 grupos):

- **Oaxaca:** concentra la mayor carga formal con 10 sanciones INE en vínculo PARES y 4 en JERARQUICA_SUBORDINACION.
- **Quintana Roo (OTRO):** 1 sanción INE frente a **1,255 casos BANAVIM** — la brecha más grande del registro, señal de alerta grave de subregistro institucional.
- **Tabasco (OTRO):** 1 sanción INE y 292 casos BANAVIM.
- **Puebla (JERARQUICA_SUBORDINACION):** 50% de portación de arma en los casos BANAVIM asociados — el más alto del registro.
- **Morelos (JERARQUICA_SUBORDINACION):** 25% de consumo de alcohol en casos BANAVIM asociados.

12. Visualizaciones integradas y hallazgos analíticos

Se generaron diez figuras compuestas a partir de los datos procesados en las fases de perfilado, limpieza y fusión, construidas con `matplotlib` y `seaborn` mediante `analisis.py`. El propósito no es únicamente visualizar frecuencias, sino evidenciar inconsistencias, subregistros y concentraciones territoriales que permanecen invisibles en los sistemas oficiales de información.

12.1. Perfil de personas sancionadas (INE)

El 54% de las resoluciones no derivaron en sanción efectiva; el 84% de los sancionados son hombres; se identificaron 12 reincidentes. Oaxaca concentra el 40% de todas las sanciones del periodo, muy por encima del promedio nacional de 12.7.

Perfil de personas sancionadas por violencia política de género — INE (2020-2022)




Figure 5: Perfil general de sanciones por violencia política de género (INE 2020-2022).

12.2. Tipos de violencia y relación con las sanciones

La violencia simbólica (122 casos) y psicológica (100 casos) son las más frecuentes. El mapa de calor evidencia que la mayoría de estas incidencias terminan sin sanción formal, lo que confirma la baja efectividad coercitiva del mecanismo institucional.

¿Qué tipo de violencia registra el INE y contra quién?

Imprimir Carta tipo "Violencia contra mujeres y niñas" (Violencia política de género) - Resguardar la víctima normalizada

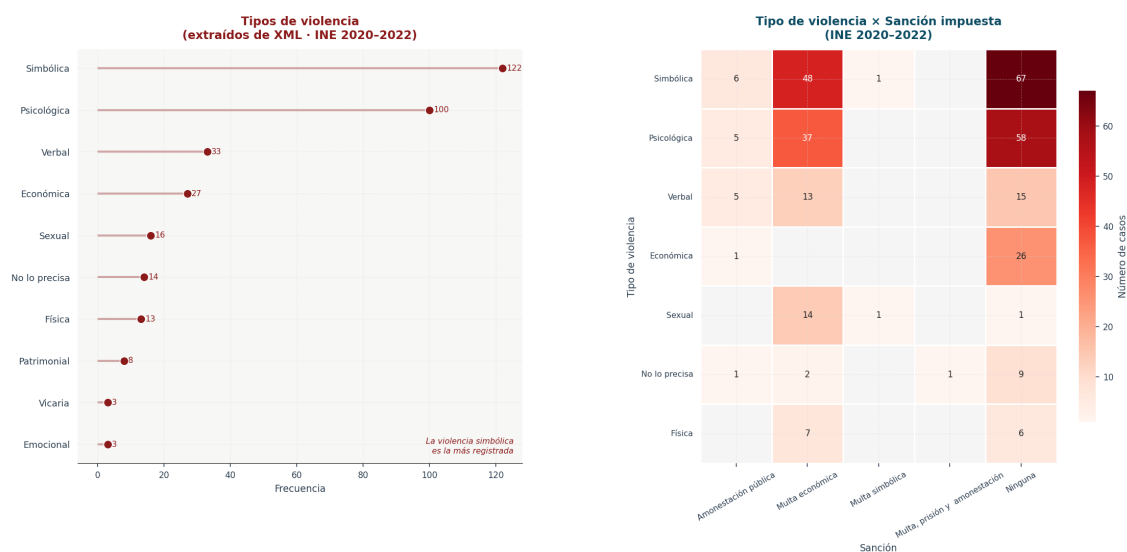


Figure 6: Distribución de tipos de violencia y sanciones impuestas (INE 2020-2022).

12.3. Distribución territorial comparada: INE vs BANAVIM

La comparación revela una desconexión sistemática entre violencia registrada y sanciones formales. Quintana Roo presenta 1,255 casos BANAVIM por cada sanción INE —la brecha más crítica del registro, incorporada en el índice de riesgo territorial.

¿Dónde ocurre la violencia de género? Distribución territorial comparada




Figure 7: Comparación territorial entre sanciones INE y casos BANAVIM.

12.4. Relaciones víctima–agresor entre fuentes

INE: poder político (PARES 61, JERARQUICA 33). BANAVIM: vínculos personales (CÓNYUGE o PAREJA: 447 k casos, EX PAREJA: 151 k). El panel de grupos homologados muestra que la categoría OTRO del BANAVIM domina numéricamente, evidenciando la ambigüedad residual que limita el linkage individual.




Figure 8: Comparación de vínculos agresor-víctima entre INE y BANAVIM.

12.5. Perfil sociodemográfico del agresor (BANAVIM)

Media de 36.4 años; el 50% entre 28 y 43 años (IQR). Predomina educación secundaria (26%) y preparatoria (13%), aunque el 36% no tiene escolaridad identificada, reflejando nulidad estructural. El 82% de las víctimas conocía a su agresor. La mediana de edad es idéntica (35 años) con y sin arma, lo que sugiere que la portación de arma no discrimina por edad sino por tipo de vínculo.

Perfil sociodemográfico del agresor — BANAVIM (806 092 registros)

Datos procesados: Imágenes reparadas con HUI, Variables duplicadas (<14 o >100 años, escolaridad), Variables semánticas y datos eliminados

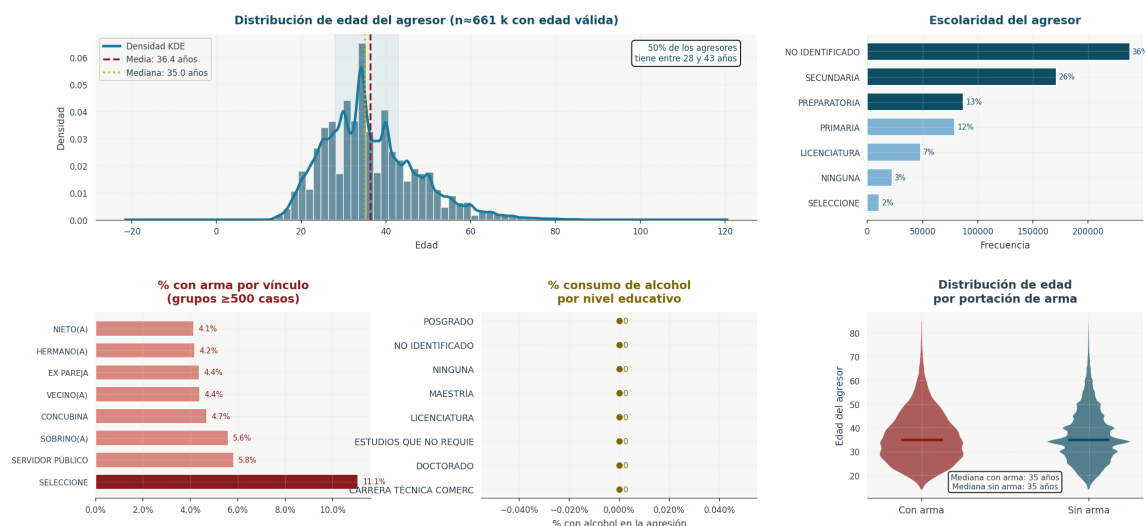


Figure 9: Perfil sociodemográfico de agresores registrados en BANAVIM (806,092 registros).

12.6. Índice de riesgo territorial integrado

Quintana Roo (0.405) y Oaxaca (0.209) encabezan el ranking. La diferencia en su composición es reveladora: Quintana Roo debe su posición casi exclusivamente al volumen de casos BANAVIM sin contraparte formal; Oaxaca combina alto volumen de sanciones formales con presencia significativa en BANAVIM. Esta diferencia sugiere intervenciones distintas para cada estado.

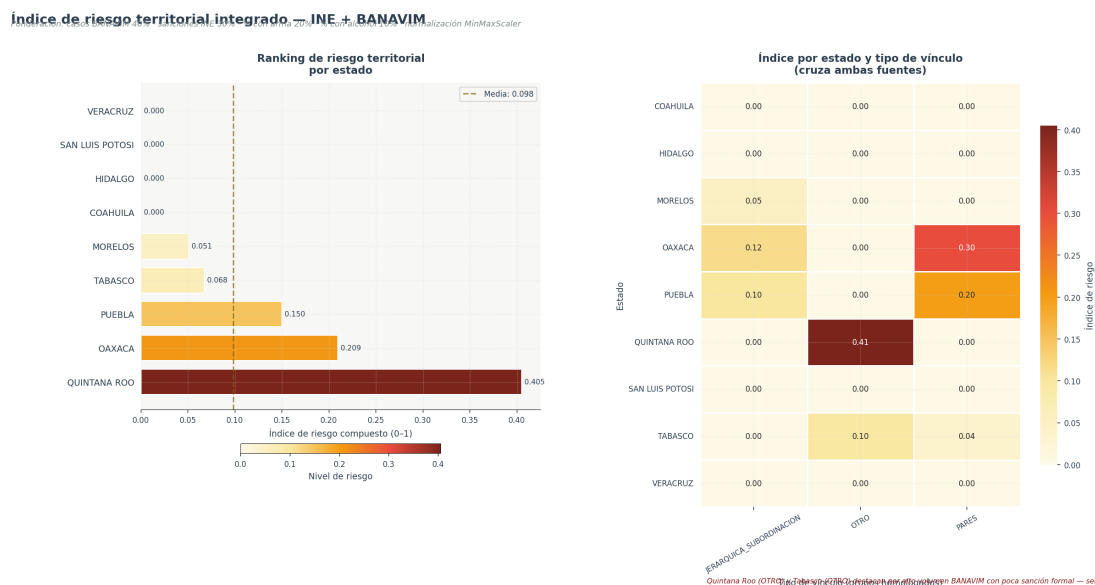


Figure 10: Índice compuesto de riesgo territorial INE-BANAVIM.

12.7. Consultas analíticas sobre el INE

Evolución temporal con pico en 2021 (93 casos); reincidencia del golden record (9%); distribución por ámbito territorial (76% municipal); top reincidentes donde Ernesto Ruiz Flandes (10 incidencias, sanción: Ninguna) destaca sobre el resto.

5 Consultas sobre el INE — datos después del procesamiento

Golden record · alias removidos · fechas parseadas · XML, extraído · columnas con <20% completitud descartadas

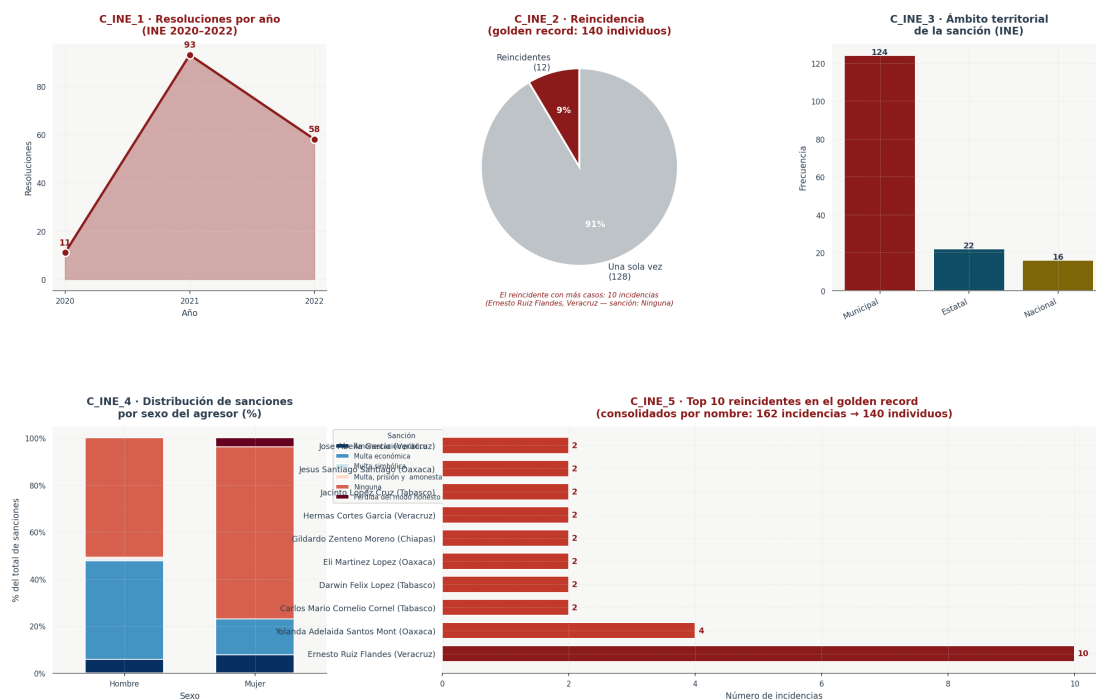


Figure 11: Consultas analíticas derivadas del INE después del procesamiento.

12.8. Consultas analíticas sobre BANAVIM

La pirámide de edad muestra concentración entre 25 y 45 años para ambos sexos. La estacionalidad muestra picos en agosto y diciembre, posiblemente relacionados con contextos de mayor convivencia. El 82% de víctimas conocía al agresor.

5 Consultas sobre el BANAIVM — datos después del procesamiento

Mojibake reparado con fity (Acapulco de Juárez) → Acapulco de Juárez; Edades atípicas excluidas; placeholders semánticos eliminados




Figure 12: Consultas analíticas derivadas de BANAVIM después del procesamiento.

12.9. Consultas multi-fuente (1–5)

La completitud de `vinculo_victima` en el BANAVIM (83.8%) es el factor más limitante para el record linkage. La distribución de sexo es consistente entre fuentes (84% hombres en INE; patrón similar en BANAVIM), lo que valida la homologación del campo.

Consultas multi-fuente (1-5) — INE + BANAVIM integradas

Las siguientes consultas cruzan simultáneamente ambas fuentes · Integración consolidada via Sorted Neighbourhood Method

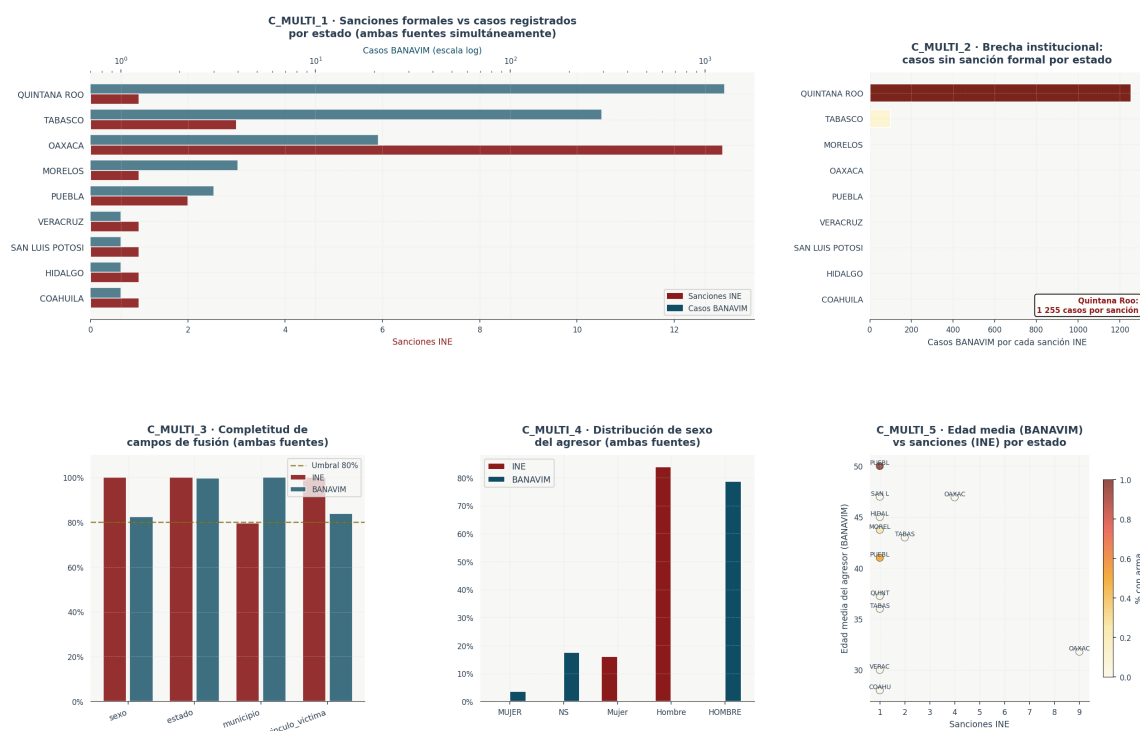


Figure 13: Consultas multi-fuente integradas entre INE y BANAVIM (1–5).

12.10. Consultas multi-fuente orientadas a política pública (6–10)

El heatmap de componentes normalizados muestra que Quintana Roo domina en el componente BANAVIM, mientras Oaxaca domina en el componente INE. Puebla y Morelos destacan en los componentes de intensidad (arma y alcohol). La distribución temporal comparada muestra que el pico del INE en 2021 no tiene correlato proporcional en el BANAVIM, lo que puede reflejar retrasos en el registro de casos entre dependencias.

Consultas multi-fuente (6-10) — hacia la política pública de prevención

Perfil integrado INE + BANAVIM. La ciencia de datos como herramienta para hacer visible lo invisible



Figure 14: Consultas multi-fuente orientadas al diseño de política pública preventiva.

13. Preguntas de negocio y análisis

13.1. P1 — Distribución de violencia y vínculos (INE)

Fuente: INE golden record (2020–2022). **Método:** Análisis descriptivo de frecuencias sobre `tipo_violencia` extraído del XML y relación agresor–víctima, con tablas de contingencia.

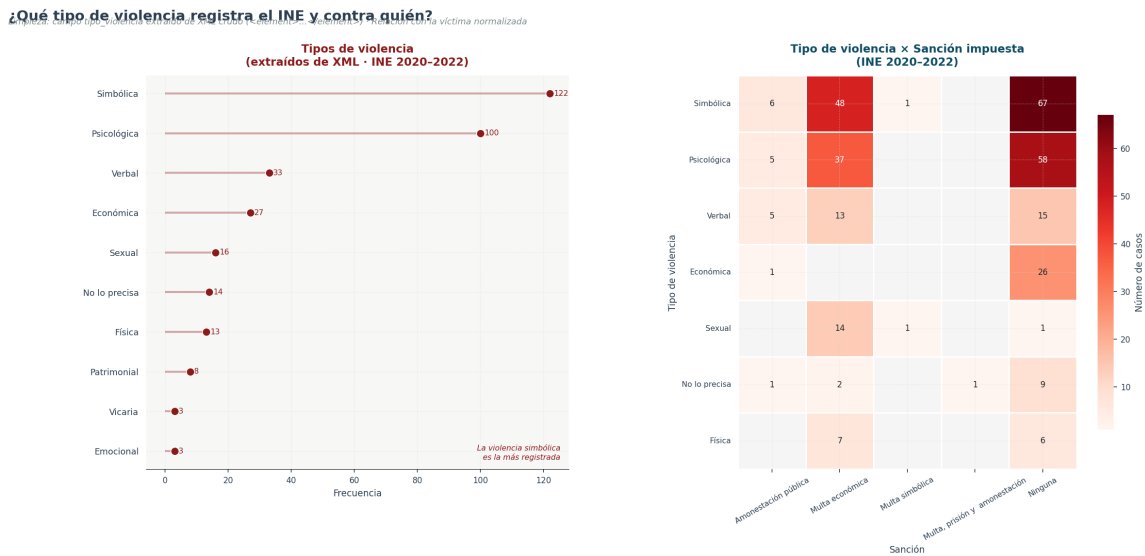


Figure 15: Tipos de violencia y relación agresor–víctima registrados en el INE.

Predominan violencia **simbólica** (122 casos) y **psicológica** (100 casos). Los vínculos más frecuentes son entre **pares políticos** (61) y relaciones **jerárquicas** (33). El 54% de los casos no recibió sanción efectiva — principalmente los de violencia simbólica, que es la categoría más documentada y la menos sancionada. Este hallazgo sugiere que el sistema institucional tiene mayor dificultad para traducir conductas simbólicas y psicológicas en sanciones formales, posiblemente por la dificultad de su acreditación jurídica.

13.2. P2 — Patrones territoriales de violencia

Fuentes: INE y BANAVIM geocodificados. **Método:** Clustering DBSCAN y K-Means sobre coordenadas normalizadas.

¿Dónde ocurre la violencia de género? Distribución territorial comparada




Figure 16: Distribución territorial de sanciones y casos.

Los clusters muestran concentración en el centro-sur del país (Oaxaca, Puebla, Tabasco, Veracruz). Los patrones de sanciones INE y casos BANAVIM son **complementarios, no coincidentes**: los estados con mayor carga formal en el INE no son los que tienen mayor volumen en el BANAVIM. Esta complementariedad es evidencia de que las dos fuentes capturan dimensiones distintas de un mismo fenómeno y de que ninguna por sí sola es suficiente para el diseño de política pública.

13.3. P3 — Comparación INE vs BANAVIM: vínculos relacionales

Fuentes: INE y BANAVIM. **Método:** Comparación de distribuciones de `vinculo_match` entre fuentes.

¿Quién agrede a quién? Relaciones víctima-agresor en ambas fuentes




Figure 17: Comparación de vínculos relacionales entre INE y BANAVIM.

El BANAVIDM concentra relaciones de pareja y familiares (cónyuge/ex pareja: 447 k casos); el INE presenta mayor presencia de relaciones entre pares e institucionales jerárquicas. Ambas fuentes documentan fenómenos distintos dentro del mismo marco de género, lo que valida la decisión de no intentar una fusión individual directa y, en cambio, construir un perfil territorial complementario.

13.4. P4 — Perfil del agresor: arma y alcohol (BANAVIDM)

Fuente: BANAVIDM (806,092 registros). **Método:** Análisis descriptivo comparativo por `vinculo_match`.

Perfil sociodemográfico del agresor — BANAVIDM (806 092 registros)

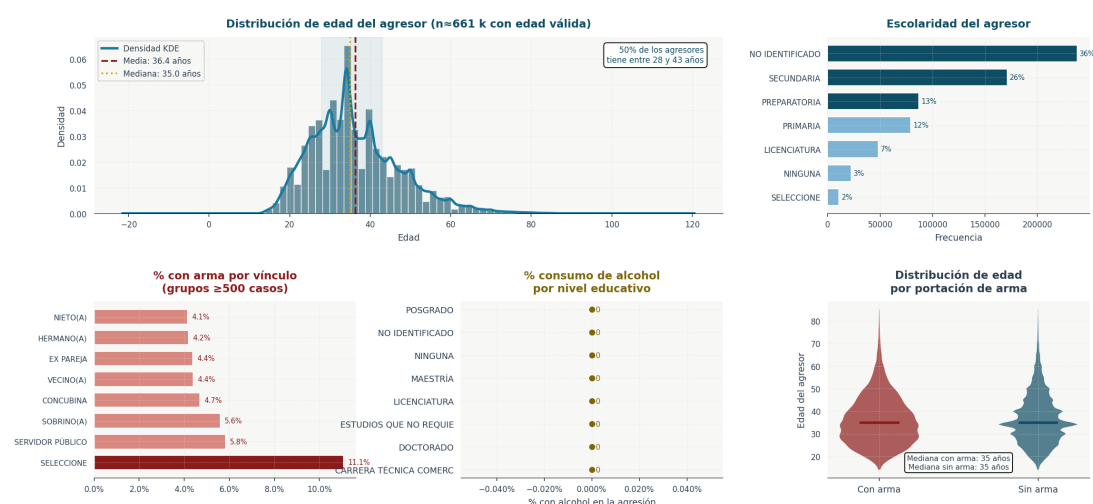


Figure 18: Perfil del agresor según vínculo relacional.

La portación de arma supera el 5% en vínculos de servidor público y sobrino/a. El consumo de alcohol está presente en más del 25% de los casos en relaciones de pareja y concubinato. La mediana de edad es idéntica (35 años) con y sin arma, lo que sugiere que la portación de arma no discrimina por edad sino por tipo de vínculo y contexto. Estos hallazgos son directamente útiles para el diseño de protocolos de atención diferenciada: las intervenciones para casos con arma deberían focalizarse en contextos jerárquicos e institucionales, mientras que las de alcohol en contextos de pareja.

13.5. P5 — Índice de riesgo territorial

Fuente: `perfil_estado_integrado.csv`. **Método:** Índice compuesto ponderado con `MinMaxScaler`.

```
1 from sklearn.preprocessing import MinMaxScaler
```



```

2
3 # MinMaxScaler: normaliza cada variable al rango [0, 1]
4 # para que sean comparables independientemente de su escala original
5 vars_riesgo = ['n_sanciones_ine', 'n_casos_banavim', 'pct_portaba_arma',
6               , 'pct_alcohol']
7 scaler = MinMaxScaler()
8 perfil_estado[vars_riesgo] = scaler.fit_transform(perfil_estado[
9               vars_riesgo].fillna(0))
10
11 # Indice ponderado: mayor peso a volumen BANAVIM (disponibilidad de
12   datos)
13 # y sanciones INE (formalidad institucional)
14 perfil_estado['indice_riesgo'] = (
15     perfil_estado['n_sanciones_ine'] * 0.30 + # peso: formalidad
16     perfil_estado['n_casos_banavim'] * 0.40 + # peso: volumen
17     perfil_estado['pct_portaba_arma'] * 0.20 + # peso: intensidad
18     perfil_estado['pct_alcohol'] * 0.10      # peso: factor
19     contextual
20 )

```

Listing 8: Construcción del índice de riesgo territorial.

Índice de riesgo territorial integrado — INE + BANAVIM





Figure 19: Índice integrado de riesgo territorial INE–BANAVIM por estado.

Top 5 estados prioritarios: Quintana Roo (0.405), Oaxaca (0.209), Puebla (0.150), Tabasco (0.068), Morelos (0.051). La composición del riesgo es diferenciada: Quintana Roo por brecha institucional (subregistro formal), Oaxaca por concentración de sanciones, Puebla por intensidad de violencia con arma. Esta diferenciación sugiere que las

intervenciones de política pública deben ser **distintas para cada estado**, no universales.

14. Conclusiones

14.1. En términos del proyecto de calidad de datos

Este proyecto demuestra que las principales fuentes institucionales sobre violencia de género en México presentan deficiencias estructurales que van más allá de los valores faltantes. El pipeline IDLA permitió sistematizar el tratamiento de cada problema:

Problema P4 (XML crudo): resuelto con la función `extraer_xml_lista`, que convierte texto embebido en XML a valores legibles mediante expresiones regulares.

Problema P5 (reincidentes sin consolidar): resuelto con `consolidar_persona`, que produce un golden record por individuo a partir de múltiples incidencias. Esto fue crítico: sin este paso, los 12 reincidentes no existirían como entidad en los datos.

Problema P3 (incompatibilidad entre fuentes): abordado en dos niveles. A nivel territorial, mediante el SNM con `vinculo_grupo` homologado. A nivel individual, mediante `vinculo_match` con niveles de confianza explícitos y validación geográfica INEGI. Ninguno de los dos abordajes resuelve el problema de fondo —la ausencia de nombre en el BANAVIM— pero lo enmarca metodológicamente de forma honesta.

Problema de mojibake (codificación): resuelto con `ftfy`, que repara automáticamente 806,092 registros en todos sus campos de texto. El caso de **Acapulco de Juárez** es el ejemplo documentado que ilustra por qué ambas fuentes no pueden unirse directamente.

Problema P2 (nulidad geográfica): parcialmente mitigado con la validación INEGI y la decisión de agregar al nivel de estado en lugar de municipio, produciendo grupos estadísticamente más robustos.

La dimensión de *aptitud para vinculación* —el porcentaje de registros con los campos de llave no nulos simultáneamente— resultó ser la métrica más determinante del pipeline: es la que define qué tipo de fusión es posible *antes* de ejecutar cualquier algoritmo de record linkage. Con 83.8% de completitud en `vinculo_victima` del BANAVIM, el linkage territorial es viable; con 0% de completitud en el nombre del agresor, el linkage individual solo puede producir candidatos probables, no matches definitivos.

14.2. En términos del dominio de negocio

Lo que los datos confirman: Los hallazgos del proyecto corroboran empíricamente lo que los indicadores nacionales ya sugerían: la violencia de género está concentrada

territorialmente (sur-sureste), ocurre principalmente en contextos conocidos (82% de víctimas conocían a su agresor), y el sistema institucional de sanción tiene una efectividad muy limitada (54% de casos sin sanción en el INE). La cifra negra del 92.9% documentada por la ENVIPE encuentra su correlato en la brecha entre Quintana Roo y Tabasco: miles de casos registrados en el BANAVIM sin una sola sanción formal en el INE.

Implicaciones para política pública: El índice de riesgo territorial permite priorizar intervenciones de forma diferenciada:

- **Quintana Roo:** prioridad en el fortalecimiento del sistema de sanción formal. La violencia existe y está documentada en el BANAVIM; el problema es la ausencia de procesos formales.
- **Oaxaca:** necesita tanto mayor sanción efectiva (el 54% sin sanción aplica también aquí) como atención a los vínculos jerárquicos institucionales.
- **Puebla:** intervenciones focalizadas en agresores con arma en contextos jerárquicos — protocolos de atención de mayor riesgo físico.
- **Morelos:** atención al consumo de alcohol como factor contextual en relaciones jerárquicas — programas de prevención articulados con salud pública.

Lo que el sistema no puede hacer todavía: Con los datos actuales, es imposible hacer seguimiento individual de agresores entre fuentes, identificar patrones de movilidad geográfica de reincidentes, o construir perfiles predictivos de riesgo individual. Estas capacidades requerirían, como condición mínima, que el BANAVIM incorpore un identificador de persona que persista entre años y entre dependencias.

Recomendaciones para el futuro: Los hallazgos de este proyecto sugieren tres líneas de trabajo:

1. **Infraestructura de datos:** diseñar un identificador único de persona para el BANAVIM que sea compatible con el INE y con otros registros del sistema de justicia. Sin este elemento, ningún algoritmo de record linkage producirá resultados confiables a nivel individual.
2. **Análisis predictivo:** con los campos sociodemográficos del BANAVIM (edad, escolaridad, vínculo, arma, alcohol) ya limpios y normalizados, sería posible construir modelos de clasificación para identificar perfiles de agresor asociados con mayor riesgo de reincidencia o de violencia grave, una vez que el tamaño de muestra lo permita.
3. **Ampliación de fuentes:** integrar el Registro Nacional de Delitos Sexuales del RNPDO, los datos del SESNSP sobre feminicidios y las bases de carpetas

de investigación del CNPJ enriquecería el perfil territorial con dimensiones que hoy no están disponibles en el INE ni el BANAVIM.

El BANAVIM fue creado para ser el gran repositorio nacional de información sobre violencia contra las mujeres. Quince años después, los problemas de calidad documentados en este proyecto confirman que el sistema no puede cumplir su función con el diseño e infraestructura de datos actuales. El perfil estadístico territorial integrado y el registro de 5 pares candidatos de alta confianza son exactamente los tipos de análisis que el BANAVIM debería poder generar —y no puede. Documentar esa brecha con evidencia empírica es, en sí mismo, una contribución para el diseño de mejores políticas de datos públicos sobre violencia de género en México.